

ELM4098.9

BİTİRME PROJESİ ARA RAPORU

Güneş Panelleri Üzerindeki Hasar ve Hataların
Yapay Zeka (YOLO) Tabanlı Otomatik Tespiti

Çift Modelli RGB ve Termal Yöneylem

Danışman	Prof. Dr. Elif SAKLAM
Tarih	24 Nisan 2026
Model Versiyonu	solar_mvp3 — v1.0.2
Mimari	YOLOv11n (Nano) — Anchor-Free

İÇİNDEKİLER

- Özet
- Giriş, Motivasyon ve Proje Donanım Envanteri
- Literatür Taraması ve Geleneksel Yöntemlerin Karşılaştırılması
- Proje Mimarisi: Çift Modelli (RGB & Termal) Yaklaşım Fiziği
- Model Seçimi: YOLOv11 Teorik Altyapısı
- Canlı Akış (Streaming) ve Çoklu Parçacıklı Mimari
- Bütünleşik Eğitim Kümesi: Dağılım ve Mozaik Çoğaltma
- Model Performansı: Çoklu Sensitivite Etkileri Analizi
- Validasyon Bloğu: Tahmin Çıktıları ve Karmaşıklık Değerlendirmesi
- Endüstri Standartları, Eksikler ve Veri Toplama Stratejisi
- Projedeki Mevcut Durum ve Sonraki Adımlar
- Kaynakça

1. Özet

Küresel ölçekte Fotovoltaik (PV) güneş enerjisi sistemlerinin kullanımı artmasıyla birlikte, sistemlerin verimini düşüren hataların denetimi hayati bir problem hâline gelmiştir. Bu projenin temel amacı, güneş panellerinin yüzeyinde oluşan fiziksel ve çevresel faktörler (toz, kar, kuru pislik, mekanik kırıklar) ile elektriksel risklerden (hotspot) doğan durumları derin öğrenme (Deep Learning) tabanlı bir nesne bulma algoritması ile havadan otonom olarak sınıflandırmaktır.

Çalışma kapsamında çift kanallı (Spektral) bir metodoloji yürütülmektedir: Birinci kanal görünür ışık tayfına odaklanan (RGB) model iken, ikinci kanal ilerleyen fazlarda projeye eklenecek olan sıcaklık farkına dayalı (Kızılötesi/Termal) sensör anomalisi tespitidir. Güncel YOLOv11 mimarisi kurularak sistemin İleri Düzey Uç Bilişim (Edge AI) Inference projesine dönüştürülmesi ve Canlı Akış (LIFO-Streaming) mekanizması ile eşzamanlı video üzerinden çalışması hedeflenmiştir.

2. Giriş, Motivasyon ve Proje Donanım Envanteri

Bir fotovoltaik güneş enerjisi tesisinin operasyonel kârlılığı (ROI), panellerin beklenen Watt çıkışı gücünü aksatmadan sağlayabilmelerine bağlıdır. Paneller; aşırı doğa koşullarına daimi olarak maruz kalan cam tabanlı yapı elemanlarıdır. Özellikle panel yüzeyinde biriken bölgesel lekelenmeler (toz kümleleri, kuru pislikleri, dal/yaprak kırıntıları) hücrelerin üzerine gölge düşürerek (Shading Effect) lokal enerji kaybı yaratır.

Sisteme seri bağlı hücre dizilerinde (Strings) meydana akım engeli, hücre üzerindeki bypass diyotlarına yüksek voltaj bindirir. Böylelikle panel alev alarak (Hotspot) tesiste yangınlara yol açabilmektedir. Geleneksel el tipi Multimetre/Megger denetimleri yüksek maliyetlidir ve yavaştır.

Proje Geliştirme Donanım Temeli

Geliştirilen "solar_mv3" modeli (Açık Kodlaması: v1.0.2), uç bilişim kısıtlamalarını simüle edebilmek adına devasa sunucular yerine ortalama bir tüketici donanımında geliştirilmiştir:

Bileşen	Özellik
İşlemci (CPU)	AMD Ryzen 7 5800H
Sistem Belleği (RAM)	16 GB DDR4
Grafik Birimi (VRAM)	4 GB (VRAM optimizasyonlu)
AI Katman	yolo11n.pt Base Modeli

3. Literatür Taraması ve Geleneksel Yöntemlerin Kısıyaslanması

Güneş enerjisi arıza analizlerine Bilgisayarlı Görü (Computer Vision) perspektifinden yaklaşıldığında, klasik görüntü filtreleme metodları ile yapay öğrenme arasında muazzam bir başarı uçurumu vardır. Literatürde mikro-kırınklar dahi çok net gösteren Elektrolüminesans (EL) Görüntülemesi metodu mükemmeldir; fakat yalnızca gece test edilebildiğinden Drone otomasyonu için uygulanabilir değildir.

Redmon vd. [2] tarafından üretilen R-CNN devrimcisi YOLO (You Only Look Once) serisi gerçek zamanlı nesne bulan sistemlerin öncüsüdür. Güneş santralleri gibi geniş matris sahalarında R-CNN tarzı bölgesel evrimi aklar taramayı dakikalarca uzatırken, YOLO mimarisi koca bir panel çiftliğini milisaniyeler içerisinde tam evrimi süzgecinden geçirir. Bu proje spesifik olarak endüstride yeni standartları YOLOv11 sürümünü kullanarak "Anchor-Free" tekniği ile panellerdeki kusurlar sınırlanmay hedeflemiştir [5].

Yöntem	Doğruluk	Hız	Gündüz Kullanım	Maliyet
EL Görüntüleme	Çok Yüksek	Yavaş	Hayır	Yüksek
Multimetre/Megger	Orta	Çok yavaş	✓ Evet	Yüksek
R-CNN Tabanlı CV	Yüksek	Orta	✓ Evet	Orta
YOLOv11 (Bu Proje)	Orta-Yüksek	Gerçek Zamanlı	✓ Evet	Düşük

Tablo 1: Yöntem Karşılaştırma Matrisi

4. Proje Mimarisi: Çift Modelli (RGB & Termal) Yaklaşım Fiziği

Piyasadaki tek yönlü projelerin aksine, bu projede endüstri standartlarına uygun olacak şekilde iki paralel Spektrum modeli kurgulanmıştır.

Kanal 1 – Yüzeysel Foton Spektrumu (RGB Model)

CMOS / Aynasız kameralarla üretilen 380nm ile 700nm arası tayf. Algoritma bu matristeki kenar zıtlıkları, renk yansımalarının deformasyonunu ve lekeleri tespit eder. Çatlak cam, kar, kuru yaprak ve toz topraklanmalar RGB ile kolaylıkla belirlenir. Aşağıda, tamamen renksel farklılıkların şekline (Morphology) duyarlıdır.

Kanal 2 – Elektromanyetik Isı Spektrumu (Termal Model)

Bypass diyotu arızası ve hücre lehim atması gibi durumların dikkatle görsel olarak mükemmel pürüzsüz görünür. Arıza, ancak hücresel kısa devrenin radyasyonlu olması (IR Bandında) sonucu tespit edilebilmektedir. Bu yüzden termal sensörlerden beslenecek %100 ayrı bir model hotspot analizi için kurgulanacaktır [4].

5. Model Seçimi: YOLOv11 Teorik Altyapısı

Çalışmada ana omurgası olarak Ultralytics'in sunduğu YOLOv11n (Nano) yapıları seçilmiştir. Yüksek uç bilişimlerdeki asgari RAM artmasına uyan bu model, bir önceki nesil versiyonlara göre C2f (Cross Stage Partial Networks) modüllerinde büyük iyileştirmeler içerir.

Bu yapı özellikle uzaktan çekilmiş küçük piksel boyutlarındaki nesnelerin (yaprak ve kuş pisliği gibi) model tabakalarından ufaltılmadan geçirilmesine yardımcı olur. SPPF (Spatial Pyramid Pooling Fast) yapısı ile mekânsal özellikler hızlı biçimde korunmaktadır.

6. Canlı Akış (Streaming) ve Çoklu Parçalı Mimari

Ekilen ".pt" model dosyalarının gerçek hayata entegrasyonu kodlanırken saniyedeki işlem (FPS) gecikmelerinin dondurulması temel sorundur. Özellikle Python dilindeki Global Interpreter Lock (GIL) tek bir bellek yapısına aynı anda yazabildiğinden video okuma esnasında yapay zeka gecikebilmektedir.

Sistemde donanım I/O yükünü sağlamak için **Producer-Consumer Thread** topolojisi benimsenmiştir:


- **VideoSource (S-T3) Thread'i:** Tamamen asenkron şekilde Drone (RTSP) veya yerelden kamerayla okur. O kareyi yalnızca bellekteki havuza iterek (Produce) görevi tamamlar.
- **FrameProcessor & YOLO Mimarisi:** İşleme başladığında, tampon gereğinden fazla dolduysa kuyruktaki eski kareler silinir. Bu teknoloji LIFO (Last-In-First-Out) olarak kodlanmıştır.
- **Annotator & Recorder:** Çizim modülünün disk kaydetme operasyonları asenkron ayrı bir Recorder işlemcisi ile diske yazdırılır; Disk I/O işlemciyi meşgul etmez.



Şekil 0: Producer-Consumer LIFO Streaming Mimarisi

7. Bütünleşik Eğitim Kümesi: Dağılım ve Mozaik Çoaltım


Projenin en kritik aşaması 5000 sentetik varyasyondan oluşan RGB Veri Yığını'nın makineye nasıl beslendiğidir. Aşağıdaki görseller Veri Dağılım matrisini ve modelin beslendiği Mozaik (Mosaic) Eğitim Kutularının tahlil etmektedir.




Şekil 1: Corelogram Sınıf Dağılımı ve Sınırlar Kutularının Boyut X-Y Dağılım Matrisleri

Model Hedef Dağılımlar (Şekil 1): Sınıf Dağılım matrisleri incelendiğinde sol üst taraftaki kolonlardan Data Imbalance (Veri eşitsizliği) açıkça sezilmektedir. Sağ alt taraftaki ebat grafiği (Bbox X/Y Histogram) analiz edildiğinde hataların tamamına yakınının küçük piksel matrislerinden (Small Object Formasyonundan) oluştuğu kanıtlanmaktadır.

Mozaik Eğitim Batch Görselleri



Şekil 2a-c: Albumentations ile Çoaltım ve 4 Panelli Mozaiklenmiş (Mosaic) Batch-0, 1, 2 Veri Grupları




Ekil 2d-f: Eğitim Son Epoch'larından (Epoch ~106000) Alınan Mozaik Batch Görselleri


Mozaik Katmanlar Analizi: Eğitim kümelerindeki görüntülere bakıldığında yapay zekanın tek bir panele sabitlenmek yerine bir görüntüyü 4 ayrı kareden süzmesi sağlanmıştır. Panel açılarının kasıtlı olarak farklı eksenlere devrilmesi (Geometrik Rotasyon / Ters Çevirme) yapay zekanın Rotation-Invariant duruma geçmesini sağlamaktadır. Brightness (koyuluk) değişiklikleri ile de ucuz kamera parlamaları taklit edilmiştir.

8. Bütünleşik Model Performansı: Çoklu Sensitivite Etkileri Analizi

Projenin "solar_mvp3" versiyonu 100 devirlik tam bir epok haritasına tabi tutulmuştur. **mAP50: %62.2, Precision: %62.8 ve Recall: %62.3** değerleri üzerinden grafiksel analiz yürütülmüştür.



Şekil 3: 100 Epoch Eğitim Metrikleri — Box Loss, Cls Loss, DFL Loss ve mAP50 Zaman Serisi



Şekil 4: (Sol Üst) Precision Eğrisi · (Sağ Üst) Recall Eğrisi · (Sol Alt) PR Eğrisi · (Sağ Alt) F1 Skor Eğrisi


Etki Uzayları ve Hata Karakteristiki Analizi

F1 Skoru Analizi: Precision ile Recall arasındaki harmonik ortalama olan F1 Erisinde güven eili 0.40–0.45 civarında zirve yapmaktadır (Peak Point). Mavi çizginin maksimumda olduğu alan, arkadaki farklı renklerin (Hotspot, Kuru Pislili vb.) hızlı çöküşüne maruz olmaktadır. Model kırıklarda kusursuzken yapraklarda ezilmektedir.


PR Erisi Analizi: PR çeyrek yuvarlağın en güçlü çizen sınıfların physical_damage ve dust_particle olduğu; ancak bu iki sınıfta ezici bir tanıma performansı yadsı görülmektedir. Fakat elektriksel hatalar ile ufak partiküllerde (yaprak/kuru pislili) Area Under Curve (Eri Altı Alan) daralmaktadır. Bu durum genel mAP istatistikini %62 civarına kitleyen temel etkidir.

9. Validasyon Bloku: Tahmin Çıktıları ve Karmaşıklık Değerlendirmesi

Modelin pratikte sahadaki vizyonunu ne kadar insansı yapabildiğini sorgulamak (Overfitting kontrolü) için ağı hiç görmediği Validasyon Matrisleri ile çarpılmıştır. Model çıktıları ve kendi yanılsama matrisinin (Confusion Matrix) karışıklığına ağıda derlenmiştir.



Ekil 5a-c: Validasyon kümesinde etiketleme olmadan sistemin tahmin ettiği Bounding Box'lar ve Güven Yüzdeleri (Batch 0, 1, 2)



Ekil 6: Modele Ait Type-1 ve Type-2 Yanılsama Geçişlerini Gösteren Karmaşıklık (Confusion) Matrisi

Gerçek Tahmin ve Type 1 / Type 2 Matris Analizleri

Panel Tahmin Performansı (Ekil 5): Yapay zekanın panel hücre silikonu üzerindeki ufak lekeler ve yapısal kırıklara çizdiği renkli çevreleyici kutuların sınırlar toleranslar oldukça incedir. Fakat bazı panellerin lehimleme birleşimlerinde karanlık gölgelenmeler veya kenar parlamaları, algoritma tarafından yanlışlıkla yaprak/toz veya kırık sınıfında kodlanabilmektedir.

Karmaşıklık Matrisi ile Temel Sınama (Şekil 6): Matris haritasına bakıldığında sistem ayrıntılı olarak Background Data yüzeyleriyle kendi parametrelerini iç içe geçirmektedir. Type 1 yanlışsamar (sinyal yokken güneş parlaklığının veya yansımaya sinyali sanma — False Positive) modeli yanlıştan temel kaynaktır.

10. Endüstri Standartları, Eksikler ve Veri Toplama Stratejisi

Mevcut iterasyondaki "solar_mvp3" RGB modeli Kavramsal (PoC — Proof of Concept) oldukça net başarıya da piyasa beklentilerinden ticari olarak uzaktır.

Endüstri Standartları (O&M; İhtiyaç)

Piyasa standartlarında bir Drone kamerasının operasyona onay alabilmesi için %85–%95 arası mAP tespiti yapılabilmesi şartnamelerce zorunludur. Yanlış negatiflerin (Type 2 Error / arızaya yok saymanın) kabul edilemezliği çok yüksektir; zira bu durum tesisi yangına götürebilmektedir.

Eksiklikler ve Gelecek Stratejisi

Tüm resim analizlerinin ortak sonucu **False Positive Yansımaya Problemidir**. Modelin veri setine hatasız fakat üzerinde bolca kamera parlaması barındıran sağlam paneller girilmediği için yapay zeka her güneş yansımalarının hasar sanabilmektedir. İyileştirme fazında:

- Background Negative görüntüler veri setine eklenerek False Positive oranı düşürülecektir.
- Öğrenme Oranı (Cosine LR) daraltılarak model hiperparametre optimizasyonuna tabi tutulacaktır.
- Hedef ticari mAP eşiği olan %85 değerine ulaşmak için yeniden fitlenmesi planlanmaktadır.

11. Projedeki Mevcut Durum ve Sonraki Adımlar

Projenin "İnşaat ve Temel Çizim Kodlaması" fazları eksiksiz atlatılmış; kodlar V1.0 düzeyinde test ortamında devreye sokulmuştur.

Faz	Açıklama	Durum
Faz 1 — Yapay Zeka	solar_mvp3 v1.0.2 eğitimini tamamlandı, analitik raporlar çıkarıldı	Tamamlandı
Faz 2 — Streaming	Producer-Consumer LIFO mimarisi Python'da iskelet olarak bitirildi	Test Aşamalarında
Faz 3 — Termal Model	Kızılötesi kamera için ayrı .pt ağırlıkları toplanacak	Planlı
Faz 4 — Edge AI	ONNX dönüşümü ve Quantization optimizasyonu (Jetson/RPi)	Planlı

Gelecek Kritik Aşamalar

- Adım 1:** RGB veri imajına 'Sağlıklı ancak Parlama/Lekeli' arka plan (Background Negative) görseller eklenip %85 ticari sınıfına taşınacaktır.
- Adım 2:** Kızılötesi kamera için tamamen ayrı .pt Termal ağırlıkları (ikinci çift faz) toplanıp model oluşturulacaktır.

- **Adım 3:** Donanımsal sınırlar cihazlarda (Raspberry Pi / Jetson Nano) çalışabilmesi adına model ONNX formatına dönüştürülecek; hız optimizasyonlarına (Quantization) gidilecektir.

12. Kaynakça

- [1] F. J. P. vd., "Review of failures of photovoltaic modules," IEA-PVPS Task 13, Uluslararası Enerji Ajansı Raporları, 2014.
- [2] Redmon, J., Divvala, S., Girshick, R., & Farhadi, A. (2016). "You only look once: Unified, real-time object detection," Proceedings of the IEEE CVPR, ss. 779-788.
- [3] Li, W., et al. (2021). "Fault Detection of Solar Panels Based on Computer Vision," Sensors, 21(5), 1845.
- [4] C. Buerhop, et al., "Reliability of IR-imaging of PV-plants under operating conditions," Solar Energy Materials and Solar Cells, 107, 154-164, 2012.
- [5] Jocher, G., et al. (2024). "Ultralytics YOLO (Version 11)," Ultralytics GitHub Arşivi.
- [6] Li, L., Wang, Z., & Zhang, T. (2023). "GBH-YOLOv5: Ghost Convolution with BottleneckCSP and Tiny Target Prediction Head Incorporating YOLOv5 for PV Panel Defect Detection," Electronics, 12(3), Article 3.